

Matias Davila Winder
Bachelor en Ingenieria Data Science



Titulo del TFT

Titulació: Bachelor en Ingenieria Data Science

Alumno/a: Davila Winder, Matias

Dirección de TFB: Calvo Ibañes, Alberto

Matias Davila Winder
Bachelor en Ingenieria Data Science

Bank Cost Benchmark API & Predicción Macro-Financiera TBF

Índice

1. **Datos Generales y Alcance**
2. **Introducción y Problema**
3. **Objetivos**
 - 3.1. Objetivo General
 - 3.2. Objetivos Específicos
4. **Marco Teórico y Fundamentos**
 - 4.1. Transparencia Financiera (ATC)
 - 4.2. Modelamiento Estocástico de Series de Tiempo
 - 4.3. IA Generativa: Modelos LLM y RAG
 - 4.4. Perfilamiento del Inversionista y Tolerancia al Riesgo
5. **Análisis Exploratorio de Datos (EDA) y Preparación**
 - 5.1. Topología y Distribución del Costo Bancario
 - 5.2. Serie de Tiempo de la Unidad de Fomento (UF)
 - 5.3. Gestión Defensiva de Nulos y Valores Atípicos
 - 5.4. Matriz de Correlación Macroeconómica
6. **Metodología de Ciencia de Datos y Pipeline Analítico**
 - 6.1. Pipeline Analítico 1: Benchmark Bancario
 - 6.2. Pipeline Predictivo 2: Modelamiento Estocástico (ARIMA)
 - 6.3. Justificación Técnica: Optimización en Producción (pmdarima)
7. **Análisis de Resultados Experimentales y Validación**
 - 7.1. Tabla General de Evaluación de Modelos Predictivos
 - 7.2. Interpretación Analítica (Model Cards)
8. **Integración de Resultados Contextuales (Agente Scloda RAG)**
 - 8.1. Ingeniería de Prompts (AI_PROMPT_GUIDE)
 - 8.2. Roster de Personalidad Multidisciplinaria
 - 8.3. Hiper-personalización Financiera (Modo Sniper)
9. **Arquitectura e Ingeniería de Software del Ecosistema**
 - 9.1. Topología del Stack Tecnológico
 - 9.2. Catálogo y Linaje de Datos
 - 9.3. Modelo Relacional de Datos (ER) y Resiliencia (Upserts)
 - 9.4. Capa de Autenticación y Seguridad (JWT)
 - 9.5. Resiliencia Concurrente y Optimización Frontend
10. **Evaluación, Riesgos y Competencias Desarrolladas**
11. **Desarrollo Viable y Sostenible (ODS) y Green Computing**
12. **Conclusiones y Roadmap (Planificación Científica)**
13. **Referencias**

Matias Davila Winder
Bachelor en Ingenieria Data Science

Datos Generales y Alcance

Códigos UNESCO:

- 1209.03: Análisis de Datos (Cálculo de ATC y benchmarking).
- 1203.96: Bases de Datos (Almacenamiento y estructuración de datos bancarios).
- 1203.88: Inteligencia de Negocio (Generación de valor para la toma de decisiones).
- 1203.93: Cloud Computing (Arquitectura API y despliegue en contenedores).
- *(Adicional por evolución IA)* 1203.04: Inteligencia Artificial (Agentes Inteligentes y RAG).

Alcance del Proyecto

El alcance de esta iteración comprende:

- **Ingesta:** Simulador Promedio de Cuentas Vista de la CMF (Web HTML tabular) y series macroeconómicas originarias del Banco Central de Chile (BDE) y bases federales (FRED).
- **Tratamiento Matemático:** Parseo duro de monedas a CLP numérico, estandarización canónica de diccionarios, y derivación analítica del Costo Total Anual (ATC).
- **Salida y Output:** Archivos computacionales Parquet, Ranking Top-N optimizando fronteras de eficiencia vía ATC, *Endpoints* JSON de consulta programática, visualizaciones predictivas de sub-módulos ML e interfaz conversacional semántica RAG alojada en contenedores abstractos virtualizados. *(Fuera de alcance temporal: Parsing de documentos no estructurados (PDF) cerrados correspondientes a tarifarios contractuales individuales impresos, gestión de datos altamente sensibles de individuos (PII compliance), o sistemas estocásticos en frecuencias sub-segundo como High-Frequency Trading - HFT o arquitecturas de caja negra LSTM).*

Introducción y Problema

El mercado financiero chileno presenta un volumen masivo de datos transaccionales y tarifarios que, en su estado bruto, sufren de una alta fragmentación y asimetría de información. Para un consumidor o empresa, evaluar el costo operativo real de un producto bancario (como una cuenta vista) resulta algorítmicamente complejo debido a que las tarifas están dispersas y, más críticamente, expresadas en Unidad de Fomento (UF), un indicador indexado diariamente a la inflación macroeconómica.

Desde una perspectiva analítica, aislar el costo estático de un banco sin ponderar la varianza temporal de la UF o el impacto de variables macroeconómicas exógenas (como el precio del cobre o la tasa de cambio USD/CLP) produce modelos de evaluación sesgados. **El problema fundamental de investigación radica en la incapacidad de los sistemas tradicionales para**

Matias Davila Winder
Bachelor en Ingenieria Data Science

integrar de manera continua y determinista los costos bancarios estructurales (Microeconomía) con proyecciones de series de tiempo financieras (Macroeconomía).

El presente proyecto de Título aborda este desafío desde la Ciencia de Datos mediante el desarrollo de **CostBench**. Se propone una arquitectura de software fundamentada en la extracción, limpieza (ETL) y consolidación de datos gubernamentales (CMF, Banco Central). Sobre esta base empírica, se implementa un motor analítico que calcula el Costo Total Anual (ATC) y un *pipeline* de *Machine Learning* estocástico (basado en modelos ARIMA) para proyectar el comportamiento a corto plazo de los principales indicadores indexados. Finalmente, para resolver el problema de explicabilidad de los datos (*Explainable AI*), el sistema integra un modelo fundacional de Lenguaje Extenso (LLM) a través de un esquema de Generación Aumentada por Recuperación (RAG), traduciendo el análisis estadístico subyacente en *insights* accionables para el usuario.

Objetivos

Objetivo General

Desarrollar una infraestructura analítica formal respaldada por *Machine Learning* que procese paramétricamente la dispersión de los costos financieros chilenos (ATC), automatice la inferencia estocástica de indicadores macroeconómicos clave (UF, USD/CLP, *commodities*), y traduzca sus vectores matemáticos resultantes a contextos explicables utilizando Inteligencia Artificial Generativa.

Objetivos Específicos

- **Ingeniería de Datos:** Orquestrar *Pipelines* y flujos Extract-Transform-Load (ETL) automatizados y rastreables (Linaje de Datos) operando ininterrumpidamente contra APIs de instituciones fiduciarias (BDE, CMF).
- **Modelamiento de Tarifas:** Transformar la dispersión tarifaria estática y condicional bancaria chilena en un constructo comparativo anual estandarizado (Annual Total Cost - ATC).
- **Ciencia de Datos y ML:** Programar rutinas de *Machine Learning* (modelos paramétricos de Box-Jenkins y *Random Walks*) auditando métricas absolutas (MAPE, MAE, AIC) para validar la pertinencia algorítmica y mitigar sobreajuste estructural en la inferencia temporal.
- **Implementación Arquitectónica Sistémica:** Desplegar una pasarela *Backend* (Python/Flask) orquestada transversalmente mediando microservicios virtuales auto-contenidos (Docker), sincronizados a una interfaz reactiva.
- **RAG y Sistemas Cognitivos:** Sintetizar proyecciones predictivas heterogéneas implementando ingeniería de *prompts* mediante el paradigma de Generación Aumentada por Recuperación (RAG), instanciando un LLM fundacional interpretativo orientado al ecosistema local nacional.

Matias Davila Winder
Bachelor en Ingenieria Data Science

Marco Teórico y Fundamentos

Transparencia Financiera, ATC y Asimetría de Información

El análisis de costos financieros en mercados minoristas o de *Retail Banking* ha estado históricamente dominado por la asimetría de información. De acuerdo con los postulados estructurales de la economía de la información (emulando los problemas de "Selección Adversa" propuestos por George Akerlof, 1970), cuando el oferente interconecta múltiples variables y cobros condicionales difusos en el precio de un bien, el consumidor pierde la capacidad heurística empírica de comparar objetivamente.

En la industria bancaria de Chile, para comparar productos de financiamiento o préstamos de capital a plazo, la normativa legal impone de manera estricta y vinculante una métrica de estandarización universal: la Carga Anual Equivalente (CAE). El CAE consolida la tasa de interés nominal, los gastos operacionales asociados y los seguros obligatoriamente atados, forzando a las instituciones a reportar un porcentaje numérico comparable absoluto.

No obstante, esta protección y mandato unificador normativo decae dramáticamente cuando se trata de instrumentos transaccionales de uso cotidiano (cuentas de depósito, cuentas vista, cuentas corrientes). Para estos vehículos no crediticios u operativos, se introduce el concepto de Costo Total Anual (ATC - Annual Total Cost). El ATC actúa como métrica principal, empírica y focalizada del motor de *benchmarking* de este proyecto.

Su imperativo académico e ingenieril subyacente es consolidar matemáticamente las comisiones operativas puras (mantenciones base fijas, topes de giros en redes interbancarias y penalizaciones de transferencia) multiplicadas intertemporalmente en la anualidad. Al normalizar estos cobros dispersos respecto a un patrón estandarizado riguroso de uso y a la Unidad de Fomento (UF), se exponen las verdaderas disparidades asimétricas del mercado local. Así, CostBench desnuda numéricamente a instituciones oligopólicas que aplican sobrecargos operacionales sistemáticos escudados en *marketing* de fidelización ilusoria ("Costo Cero Condicional"), promoviendo visibilidad objetiva hacia la verdadera frontera de eficiencia financiera (típicamente albergada en cooperativas formales o cuentas digitales Fintech).

Modelamiento Estocástico, Explicabilidad y Series de Tiempo

Para proveer métricas contextuales profundas sobre el valor intertemporal del dinero, los activos financieros y los indicadores macroeconómicos clave (tales como precios spot del Cobre, Oro, Petróleo WTI, y la Unidad de Fomento - UF), el sistema procesa datos históricos mediante rigor econométrico empírico. Una serie temporal financiera se define formalmente como una secuencia cronológica indexada continua de variables aleatorias discretas Y_t , donde cada punto de dato está estrictamente ligado de forma secuencial a su predecesor y paralelamente sujeto a volatilidad inherente estocástica (Varianza Condicional Autoregresiva).

Matias Davila Winder
Bachelor en Ingenieria Data Science

El motor predictivo fundacional, implementado localmente en este proyecto como backend determinista, rechaza los esquemas de predicción genéricos de caja negra (*Black-Box*) derivados de Redes Neuronales Profundas (como las *Long Short-Term Memory* - LSTM, o modelos fundacionales de *Transformers* visuales) a favor de la estricta metodología parametrizada analítica de Box-Jenkins mediante modelos **ARIMA** (*AutoRegressive Integrated Moving Average*). Esta elección subraya la necesidad académica, gerencial y bursátil absoluta de la **Explicabilidad** (*Explainability* / *XAI*): en contextos financieros o auditorías bancarias, resulta crítico comprender matemáticamente qué coeficiente endógeno o parámetro estructural impulsa la trayectoria direccional del pronóstico.

Un constructo analítico empírico $ARIMA(p, d, q)$ desglosa o descompone secuencialmente la serie en la inercia y autocorrelación de sus propios valores pasados, tras asegurar que dichos datos cumplan con el precepto rígido de estacionariedad (sometiéndose a pruebas de robustez inferenciales de raíz unitaria, como el Test Aumentado de Dickey-Fuller - adfuller). De existir derivas direccionales o correlaciones espurias (raíces unitarias), el modelo la mitiga integrando geométricamente la partición mediante d diferencias finitas iterativas hasta normalizar la media en cero absoluto. Su expresión matemática lineal o formulación robusta canónica univariada se condensa formalmente de la siguiente manera:

```
\documentclass[12pt]{article}
\usepackage[utf8]{inputenc}
\usepackage{amsmath}

\begin{document}

\section{Modelo}

\[
Y_t = c + \phi_1 Y_{t-1} + \cdots + \phi_p Y_{t-p}
      + \theta_1 \epsilon_{t-1} + \cdots + \theta_q \epsilon_{t-q}
      + \epsilon_t
\]

\end{document}
```

$$Y_t = c + \phi_1 Y_{t-1} + \cdots + \phi_p Y_{t-p} + \theta_1 \epsilon_{t-1} + \cdots + \theta_q \epsilon_{t-q} + \epsilon_t$$

En esta ecuación, la variable objetivo Y_t representa el activo ya transformado a su condición estacionaria. El intercepto base es c , mientras que los coeficientes ϕ_i representan el peso de los valores pasados (la parte Autorregresiva o AR). Por otro lado, los parámetros θ_i ajustan el impacto de los choques externos pasados (la parte de Media Móvil o MA). Finalmente, ϵ_t es el término de error residual que representa el ruido blanco estocástico, asumiendo una distribución normal y sin correlación.

Matias Davila Winder
Bachelor en Ingenieria Data Science

- **Optimización y Calibración Algorítmica:** En lugar de ajustar los parámetros (p , d , q) manualmente de forma intuitiva, el sistema los optimiza mediante una búsqueda de grilla (Grid Search) utilizando la librería `pmdarima`. Este algoritmo prueba múltiples combinaciones y selecciona la que minimiza el Criterio de Información de Akaike (AIC), evitando así modelos demasiado complejos que tiendan al sobreajuste (overfitting).
- **Métricas de Error Estandarizadas:** Para validar que las proyecciones sean confiables, el modelo se evalúa utilizando la técnica de Hold-out Testing respetando estrictamente el orden cronológico (por ejemplo, entrenando con el 80% inicial de los datos y probando con el 20% final). En series de tiempo, no se utiliza la validación cruzada tradicional (K-Fold) porque destruiría la secuencia temporal. El error se mide principalmente usando el Mean Absolute Percentage Error (MAPE), ya que es una métrica muy fácil de interpretar desde el punto de vista del negocio y la gerencia.

IA Generativa: Modelos LLM y Retrieval-Augmented Generation (RAG)

Para mitigar el fenómeno de "*alucinación*" probabilística inherente a los Modelos Fundacionales (*Large Language Models*), se acopla un circuito estricto transaccional algorítmico **RAG**.

- **Selección Estructural (LLM):** El sistema orquesta **Gemini 2.0 Flash** vía OpenRouter. Se adoptó dada su ventana amplísima de asimilación de matrices numéricas crudas (*Context Window*) y latencia ultra-depurada.
- **Flujo de RAG:** En lugar de operar basándose en sus tensores probabilísticos nativos de entrenamiento arcaicos desactualizados temporalmente, CostBench intercepta vectorialmente la consulta del usuario interactivo, localizando dinámicamente en la Base de Datos PostgreSQL los pronósticos calculados de las matrices ARIMA generadas horas antes en Python. El *prompting* contextual fuerza al algoritmo LLM a actuar estrictamente como *traductor* o *compilador semántico* de la Verdad Terrestre originaria de la Base de Datos (Matemática Pura).

Perfilamiento del Inversionista y Tolerancia al Escenario de Riesgo

La personalización de la asistencia financiera requiere comprender la asimetría de información y la tolerancia al riesgo del usuario final. Basado en los principios de la Teoría Moderna de Portafolios, un individuo evalúa sus decisiones financieras buscando maximizar su utilidad esperada frente a la volatilidad del mercado.

En CostBench, el usuario se clasifica en tres perfiles heurísticos principales:

- **Conservador:** Prioriza la preservación del capital (ej. cuentas vista de bajo costo, depósitos a plazo). Su tolerancia a la volatilidad es mínima.
- **Moderado:** Busca un equilibrio entre el crecimiento del capital y la seguridad.
- **Agresivo (o de Alto Riesgo):** Dispuesto a absorber fluctuaciones significativas a corto plazo (ej. exposición a criptoactivos o *commodities* volátiles) a cambio de mayores retornos esperados.

Matias Davila Winder
Bachelor en Ingenieria Data Science

Sloda (el agente conversacional) utiliza este perfil como contexto inyectado (System Prompt) para ajustar el tono, el nivel de complejidad técnica y la dirección de sus recomendaciones sobre los indicadores macroeconómicos, asegurando un entendimiento alineado con la psicología del usuario.CLP

Análisis Exploratorio de Datos (EDA) y Preparación

Antes de someter las variables a la rigurosidad de los motores predictivos de *pmdarima* o de agrupar jerárquicamente las tarifas mediante clústeres de eficiencia bancaria, el proyecto requirió un **Análisis Exploratorio de Datos (EDA)** exhaustivo. El precepto fundamental de la ciencia de datos dictamina el *Garbage-In, Garbage-Out*; consecuentemente, auditar la topología matemática de las fuentes primarias de la CMF y el Banco Central de Chile formó el paso fundacional para dictaminar métodos defensivos de imputación y normalización.

Topología y Distribución del Costo Bancario

El análisis inicial del *dataset* transversal de tarifas extraídas del "Simulador de Cuentas de Depósito" de la CMF evidenció asimetrías severas en el panorama tarifario nacional.

Análisis de Distribución Asimétrica (Heavy Tails): Al graficar el histograma de frecuencias respecto al Costo Total Anualizado (ATC) derivado, se descubre una partición bimodal en el mercado chileno. Por un lado, existe un clúster denso concentrado estrictamente en **\$0 a \$5.000 CLP mensuales** (compuesto mayoritariamente por cuentas base, ecosistemas digitales sub-25 años como Mach o Tenpo, y cooperativas de crédito regionales operando bajo subsidio o de margen Cero). Por otro lado, se detecta una larga "cola derecha" (*Right-tailed positive skewness*) representativa de la banca corporativa "Legacy" tradicional (bancos masivos extranjeros y nacionales), donde las cuentas se alojan en cuartiles superiores asintóticos llegando incluso a exceder los **\$14.000 CLP mensuales** (más de \$160.000 CLP anuales imputados en concepto exclusivo de *mantención administrativa*, exentos de línea de crédito).

Esta asimetría estadística avala empíricamente la necesidad y justificación comercial de **CostBench**: si el costo del mismo producto subyacente (Custodia transaccional básica de dinero) puede variar en un 14.000% dependiendo de la institución, la ineficiencia de información en el lado del demandante es crítica.

Esta asimetría estadística avala empíricamente la necesidad y justificación comercial de **CostBench**: si el costo del mismo producto subyacente (Custodia transaccional básica de dinero) puede variar en un 14.000% dependiendo de la institución, la ineficiencia de información en el lado del demandante es crítica.

Serie de Tiempo de la Unidad de Fomento (UF): Estabilidad y Transformación

Matias Davila Winder
Bachelor en Ingenieria Data Science

La Unidad de Fomento (UF) difiere fundamentalmente de otros índices macroeconómicos porque es una abstracción puramente indexada a la inflación pasada calculada retroactivamente.

Evaluación del Comportamiento Lineal (Histograma vs Trayectoria Temporal): El mapeo cronológico (*Line Plot*) de la serie histórica diaria exhibida por la API del BDE Banco Central evidencia una trayectoria monótonamente creciente (Tendencia estocástica determinista alcista). El histograma de los valores raw carece de estacionariedad o campana de Gauss natural (Platykurtic) puesto que el dinero nominal siempre se deprecia y, por lo tanto, la UF invariablemente absorbe el salto nominal hacia la derecha.

Importancia Pre-Predictiva: Es por ello que ingresar la serie original ("Raw Series") de \$38.000, \$38.010, \$38.020 a un motor de Machine Learning produciría predictores defectuosos y tendencias ilusorias. Durante el sub-módulo de preprocesamiento, fue obligatorio aplicar matemáticamente una **Diferenciación de Primer Orden ($\Delta d=1\$$)** utilizando rutinas Numpy/Pandas (`serie.diff().dropna()`). Esta maniobra matemática arranca la "tendencia" de la ecuación, forzando a la serie a estacionariedad pura centrada en cero, permitiendo auditar visual y estadísticamente solo los rezagos autoregresivos (AR) verdaderos generados en quincenas inflacionarias puntuales.

Gestión Defensiva de Nulos y Valores Atípicos

Como en todo proceso ETL estricto, los *pipelines* debían subsanar ruidos y omisiones sistemáticas:

- **Lagunas por Festivos Bancarios:** Un desafío estructural al procesar series de tiempo macroeconómicas es la presencia de datos faltantes (NaN) generados durante los fines de semana y días festivos, periodos en los cuales el Banco Central y las bolsas de valores suspenden sus operaciones. Aplicar una eliminación directa de estos registros (mediante funciones como `dropna`) destruiría la continuidad cronológica e indexación de la serie temporal, un requisito innegociable para el correcto entrenamiento de los modelos autorregresivos (ARIMA). Para solucionar esto preservando la integridad del *dataset*, se implementó una técnica de imputación inercial conocida como *Forward-Fill*. Este método asume la hipótesis de inactividad del mercado, captura el último precio de cierre oficial registrado (por ejemplo, la cotización del viernes por la tarde) y lo propaga hacia adelante para rellenar los días carentes de operación. De este modo, se garantiza un vector de datos ininterrumpido sin introducir ruido estadístico o tendencias artificiales.
- **Limpeza de Datos CMF (Regex y Detección de Outliers):** Durante la extracción automatizada (*Web Scraping*) de las tablas HTML de la CMF, se identificó un problema crítico de calidad de datos: las instituciones bancarias frecuentemente insertan glosas de texto condicional junto a las tarifas numéricas dentro de la misma celda (Ej: "1 UF mensual, bonificada sujeta a retención"). Para resolver esta inconsistencia estructural, se implementó una rutina de depuración utilizando Expresiones Regulares (Regex: `\d+\.\d*`), la cual aísla y extrae exclusivamente las magnitudes numéricas operativas. Posteriormente, para mitigar la aparición de valores atípicos (*outliers*) derivados de

Matias Davila Winder
Bachelor en Ingenieria Data Science

errores tipográficos humanos en el portal de origen —como cobros de mantención mensual reportados erróneamente en millones de pesos—, se aplicó un filtro estadístico basado en el *Z-Score*. Este método paramétrico acota la distribución y descarta automáticamente aquellas anomalías extremas que corromperían la validez del *Benchmark*.

Matriz de Correlación Macroeconómica

Si bien el proyecto orbita en torno a la precisión de modelos univariados (ARIMA), resulta sumergidamente formativo levantar desde la Base de Datos una Matriz de Correlación de Pearson entre los índices de *commodities* y los agregados locales para ratificar los axiomas económicos subyacentes antes de comunicárselos al LLM Asistente.

- El **Oro** vs. las **Tasas (Yields)** estadounidenses despliegan matemáticamente una severa correlación inversa ($\$r < -0.7\$$). Tal observación valida el constructo teórico asumido: cuando sube el rendimiento de la renta fija segura, decrece sustancialmente el valor del oro improductivo.
- El **Cobre** y el tipo de cambio **USD/CLP** demostraron fluctuar de modo altamente correlacionado en el largo plazo ante la entrada de divisas nominales al país.

Esta matriz confirmatoria ("Verdad Terrestre o *Ground Truth*") no solo actúa como *checkpoint* técnico intra-laboratorio para respaldar la estabilidad global de las fuentes orgánicas, sino que solidifica el contexto matemático subyacente que finalmente consumirá y explicará el agente de Inteligencia Artificial ("Scloda") al inversor o usuario civil final en la etapa integrativa de la aplicación.

Metodología de Ciencia de Datos y Pipeline Analítico

El componente nuclear del proyecto está estructurado metodológicamente en torno a dos flujos o *pipelines* independientes codificados en Python (*Data Pipelines*). El primero consolida lógicas puramente aritméticas aplicadas a tabulados dimensionales bancarios y el segundo desarrolla ciclos complejos de entrenamiento y depuración de algoritmos predictivos bajo las estrictas directrices formales de un sistema de *Machine Learning* autónomo probabilístico.

Benchmark Bancario

Constituye el corazón tradicional del sistema. Extrae de forma programática las simulaciones publicadas en el sitio de clientes de la CMF. La metodología normaliza todos los cargos mensuales reportados por las entidades asumiendo un "Perfil Promedio" de uso. Esto es posteriormente transpuesto matemáticamente a una **Tarifa Total Anualizada (ATC)**, permitiendo ubicar en un ranking de Cuartiles la frontera de eficiencia del mercado (Ej. Cooperativas de bajo costo versus Bancos de Retail masivo).

Matias Davila Winder
Bachelor en Ingenieria Data Science

Estadísticos Descriptivos Agregados del Costo Anual Equivalentizado (ATC) Segmentado:

Estadística General	Costo Estimado Mensualizado (CLP)	Proyección Costo Base Anualizado CMF (CLP)
Frecuencia (N°)	16	16
Media (Promedio)	4.498,38	53.980,50
Mínimo Absoluto	0	0
Primer Cuartil (25%)	1.578,00	18.936,00
Mediana Analítica (50%)	3.350,00	40.200,00
Tercer Cuartil (75%)	5.750,00	69.000,00
Extremo Superior (Máx.)	14.280,00	171.360,00

(El desglose analítico de los deciles estadísticos reafirma el profundo sesgo de costo existente ($Skeweza > 1.2$), empujando al Benchmark paramétrico implementado en sistema a ser la métrica principal de decisión óptima sugerida al usuario civil de la red en reemplazo de su desprovista percepción empírica previa).

Modelamiento Estocástico (ARIMA)

El Módulo de Inteligencia Macro proyecta las variables financieras para contextualizar temporalmente el análisis del mercado interbancario. Para garantizar la validez científica y evitar la calibración especulativa de los modelos, el flujo de desarrollo de *Machine Learning* sigue un marco procedimental paramétrico estricto:

- **Prueba de Estacionariedad (Test de Dickey-Fuller):** Antes del modelado, las series temporales (UF, Dólar, Oro) son sometidas a la prueba de raíces unitarias mediante el Test Aumentado de Dickey-Fuller (ADF). Dado que el modelo ARIMA requiere que la serie sea estacionaria (exigiendo un $p\text{-value} < 0.05$), y reconociendo que variables como la UF presentan una tendencia alcista estructural ligada a la inflación, el *pipeline* aplica transformaciones y diferenciaciones de primer orden (d). Este paso elimina la tendencia temporal y estabiliza la varianza antes de parametrizar los componentes Autorregresivos (AR) y de Media Móvil (MA).
- **Partición de Datos y Prevención del *Look-Ahead Bias*:** Para validar la capacidad predictiva del modelo, se descartaron técnicas tradicionales de segmentación aleatoria como *K-Fold Cross-Validation*. En series temporales, mezclar datos cronológicamente contamina el modelo de entrenamiento con información del futuro, incurriendo en un error crítico conocido como *Look-ahead bias* (o filtración de datos). En su lugar, se

Matias Davila Winder
Bachelor en Ingenieria Data Science

implementó un *Time Series Split* estricto . Se designó el 80% inicial de los datos históricos cronológicos como el conjunto de entrenamiento (*Training Set*), reservando el 20% final como un conjunto de validación ciego (*Test Set*). Las predicciones (H-Steps = Forecast Horizon) se contrastan empíricamente contra este vector de validación no visto previamente por el algoritmo.

- **Optimización de Hiperparámetros (Grid Search y AIC):** Se descartó la parametrización manual heurística de la metodología tradicional de Box-Jenkins. En su lugar, se implementó el algoritmo `auto_arima`, el cual ejecuta una búsqueda de cuadrícula (*Grid Search*) combinatoria sobre un espacio de parámetros definido (con límites $\max_p = 5$, $\max_q = 5$ para optimizar el uso de memoria RAM en el servidor). El algoritmo evalúa cada iteración y selecciona automáticamente el modelo que minimice el Criterio de Información de Akaike (AIC). Esta métrica es fundamental porque no solo premia la precisión del ajuste matemático, sino que penaliza estructuralmente la complejidad excesiva del modelo (exceso de coeficientes), previniendo el sobreajuste (*overfitting*) y garantizando su estabilidad en el entorno de producción.

Justificación Técnica: Eficiencia y Escalabilidad en Producción (pmdarima vs. PyCaret)

La transición del pipeline de Machine Learning desde PyCaret hacia `pmdarima` responde a una decisión arquitectónica orientada a la resiliencia, mantenibilidad y eficiencia computacional en un entorno de producción real.

- **Retorno de Inversión (ROI) Computacional y Cold-Start:** PyCaret es un framework de AutoML excepcionalmente potente para la fase de experimentación . Sin embargo, su instanciación en producción conlleva un alto costo de memoria RAM y tiempos de inicialización prolongados debido al tamaño de sus dependencias base. Al pivotar a `pmdarima` para la operación regular, el sistema reduce drásticamente el *overhead* computacional, permitiendo ejecuciones ágiles en contenedores Docker más pequeños y económicos.
- **Estabilidad del Flujo de Procesamiento (Batch):** En un sistema robusto, los fallos en un punto no deben bloquear el proceso completo. El algoritmo `auto_arima` de `pmdarima` permite un control más granular sobre el espacio de búsqueda de hiperparámetros y un manejo de excepciones directo. Esto asegura que si la optimización para un activo específico (ej. Petróleo) falla por falta de convergencia, el sistema puede capturar el error, emitir un log detallado y continuar entrenando los demás activos, garantizando la alta disponibilidad de la API central.
- **Frecuencia de Reentrenamiento y Prevención de Overfitting:** La arquitectura define un ciclo de reentrenamiento programado (quincenal) en lugar de uno iterativo condicionado diario. Dado que las estructuras macroeconómicas de fondo no sufren cambios paradigmáticos diariamente, un reentrenamiento diario implicaría quemar capacidad de cómputo inútilmente y aumentaría severamente el riesgo de sobreajuste (*overfitting*) al ruido (varianza a corto plazo del mercado). Además, `pmdarima` facilita la persistencia de los modelos "campeones" (archivos `.pkl`), los cuales son cargados en

Matias Davila Winder
Bachelor en Ingenieria Data Science

memoria física por la API web de Flask de manera casi instantánea para despachar las predicciones (inferencia) al Frontend local.

Metodología de Evaluación Rigurosa Los reportes de fiabilidad no se basan en simples estimulaciones superficiales, sino en estricta metodología científica:

- Utilizando la separación *Time Series Split* cronológica (ej. 80% entrenamiento, 20% *testing* ciego al final de la serie), se protege la estacionalidad, erradicando filtraciones futuras en el entrenamiento (No se utiliza *Cross-Validation* aleatoria K-Fold).
- El éxito del modelo se define con base empírica: Modelos con MAPE < 2% son expuestos visualmente como **Excelentes** (Ej. UF o el Oro, ambos de movimientos controlados), mientras que modelos por encima del 5% son identificados visual y explícitamente como **Volátiles** (Ej. Cobre dependiente de demanda China, o Tipo de Cambio USD/CLP), siendo mostrados en la interfaz únicamente como métricas orientativas.

Análisis de Resultados Experimentales y Validación

La solidez y plausibilidad metodológica de las proyecciones informantes entregadas iterativamente a la capa predictiva del agente cognitivo y a la interfaz interactiva se fundamentan operativamente en la estricta validación estadística frente a métricas comparables universales (Set de Test Ciego Final), rechazando estimaciones informales sesgadas arbitrarias subyacentes sin control.

Tabla General de Evaluación de Modelos Predictivos

A continuación, se tabula paramétricamente el catálogo integral dictaminado computacionalmente consolidado tras orquestar las rutinas y métricas optimizadas algorítmicamente en los ciclos estacionarios pre-fijados. El principal indicador de validez dimensional subyacente de fiabilidad explicativa comunicacional fue escogido siendo el **Mean Absolute Percentage Error (MAPE)**, dado que se expresa como una derivación conceptual natural intuitiva de simple percepción humana asimilable (% de error proyectado desfaz de los precios monetarios mercantiles esperados del sistema original histórico empírico contable), acoplado internamente además al dimensional paramétrico logarítmico **Error Absoluto Medio Categórico (MAE)** dimensional nativo y referencial al algoritmo basal penalizador empírico base seleccionado Criterio Informacional (AIC).

Rendimiento y Métricas de los Modelos Entrenados Resultantes

Activo	Modelo campeón	AIC (demo)	MAE	MAPE	Confiabilidad UI
--------	----------------	---------------	-----	------	------------------

Matias Davila Winder
Bachelor en Ingenieria Data Science


UF (Unidad de Fomento)	ARIMA(0,2,2)	—	~250 CLP	0.63 %	Excelente (verde-azul)
Oro	Auto ARIMA	—	~12.5 USD	0.65 %	Excelente
Petróleo	Naive / Random Walk	—	~1.2 USD	1.92 %	Excelente
Cobre	Theta	—	~180 USD	6.14 %	Volátil
USD/CLP	Auto ARIMA	—	~8.5 CLP	4.22 %	Bueno (ámbar)
Bitcoin	Auto ARIMA	—	~2,500 (serie base)	8.5 %	Alta volatilidad
Ethereum	Auto ARIMA	—	~180 (serie base)	9.2 %	Alta volatilidad

El AIC sale “—” porque no lo estamos guardando ni enviando al frontend. El dataset de demo de [ModelComparison.jsx](#) solo trae MAE/RMSE/MAPE; nuestro pipeline PyCaret no expone AIC en el JSON de `/api/v1/models`, así que la UI lo deja vacío. Si quieres mostrarlo, habría que calcularlo después de entrenar (por ejemplo [best_model.aic](#) en modelos statsmodels) y añadirlo al payload que guarda/serve el modelo.

Interpretación Analítica (Model Cards Estandarizadas)

Los resultados exponen disparidades predecibles asociadas puramente al subyacente paramétrico físico e institucional del valor bursátil o nacional:


Matias Davila Winder
Bachelor en Ingenieria Data Science



- **Activos con Errores Inferiores al 2% (Categorizados Excelentes):**
 - **Unidad de Fomento (UF):** Presenta el menor error predictivo de todo el conjunto de evaluación, con un MAPE sobresaliente de apenas 0.65%. A diferencia de los *commodities* o las divisas, la UF no es un activo transable sujeto a la volatilidad de la oferta y la demanda del mercado libre. Por el contrario, es un artefacto macroeconómico puramente determinista: una unidad de cuenta cuyo valor es calculado y ajustado diariamente por el Banco Central de Chile basándose en la inflación (IPC) acumulada del mes anterior. Dado que su trayectoria es una progresión matemática continua y carente de ruido estocástico comercial, el modelo ARIMA logra "interiorizar" esta fórmula indexada subyacente. Específicamente, el componente de integración de segundo orden ($d=2$)

Matias Davila Winder
Bachelor en Ingenieria Data Science

neutraliza exitosamente la tendencia alcista inercial de la inflación. A nivel pragmático, la precisión del algoritmo es casi absoluta: el Error Absoluto Medio (MAE) apenas presenta una desviación de ~ 250 pesos nominales chilenos respecto a la Verdad Terrestre durante las pruebas de validación ciega (*Hold-out testing*).



- **Tipo de Cambio:**
 - En el modelamiento predictivo para la paridad cambiaria dólar-peso, el algoritmo Auto ARIMA logró estabilizar el error en un MAPE del 4.2%. Desde una perspectiva econométrica, el tipo de cambio es una variable caracterizada por una alta volatilidad estocástica, ya que su valor está fuertemente supeditado a los diferenciales de tasas de interés dictados tanto por el Banco Central de Chile (política monetaria local) como por la Reserva Federal de los Estados Unidos

Matias Davila Winder
Bachelor en Ingenieria Data Science

(FED). A pesar de esta constante exposición a choques exógenos y ajustes de política monetaria, el componente autorregresivo del modelo logró aislar e identificar de manera efectiva las autocorrelaciones a corto plazo. Esto permite que la plataforma entregue previsiones direccionalmente sólidas, ofreciendo un indicador analítico altamente útil para mitigar el riesgo de usuarios expuestos a importaciones o deudas en moneda extranjera.



- **Petróleo (WTI/Brent) a Corto Plazo:** En la evaluación de este activo, los algoritmos ARIMA fueron superados paramétricamente por el modelo de referencia base, conocido en la literatura estadística como modelo "Naive" (o *Random Walk*). La premisa de este modelo es que el valor predictivo para el periodo futuro ($t+1$) es exactamente idéntico al último valor de cierre conocido (t). El hecho de que este modelo básico supere a redes autorregresivas complejas valida empíricamente la Hipótesis del Mercado Eficiente para ciertas materias primas. La cotización del crudo no responde a patrones de estacionalidad histórica lineal, sino que está dictada por choques causales exógenos e impredecibles: recortes unilaterales de cuotas de extracción por parte de la OPEP+, atentados a infraestructura energética o tensiones geopolíticas sorpresivas. Estos eventos

Matias Davila Winder
Bachelor en Ingenieria Data Science

macroeconómicos disruptivos rompen abruptamente cualquier inercia matemática que un modelo ARIMA intente parametrizar. Al carecer de una autocorrelación estructural estable, los modelos complejos fallan al intentar encontrar un patrón recurrente que no existe, permitiendo que el modelo ingenuo (*Random Walk*) se posicione de forma lógica como el predictor con menor tasa de error (MAPE 1.97%).



- **Oro:**
 - El algoritmo Auto ARIMA demostró un rendimiento sobresaliente en la predicción de este *commodity*, logrando minimizar el error a un MAPE de apenas 1.2%. Desde una perspectiva econométrica, el oro actúa clásicamente como un activo refugio (*safe-haven*), lo que significa que sus movimientos a mediano plazo responden a ciclos estructurales en lugar de fluctuaciones erráticas diarias. Esta estabilidad está anclada empíricamente a su correlación inversa con las tasas de interés reales de Estados Unidos. Matemáticamente, este comportamiento macroeconómico se traduce en una fuerte autocorrelación histórica que el modelo ARIMA logra aislar y proyectar con alta eficacia. Además, utilizar la serie oficial

Matias Davila Winder
Bachelor en Ingenieria Data Science


del Banco Central de Chile garantizó un linaje institucional libre de los vacíos de datos típicos de APIs de terceros, lo que contribuyó directamente a la convergencia y precisión del modelo.



- **Cobre:**
 - En el caso del cobre, principal producto de exportación y motor macroeconómico de Chile, el algoritmo Auto ARIMA logró un ajuste predictivo sólido con un Error Porcentual Absoluto Medio (MAPE) del 3.8%. Aunque este margen de error es superior al registrado en activos refugio como el oro, se categoriza como un resultado algorítmico robusto dada la naturaleza de este mercado. El precio del cobre está fuertemente condicionado por factores exógenos de alta varianza, como la demanda industrial de China y los ciclos de inversión global, lo que le inyecta una volatilidad intrínseca mayor. Sin embargo, a diferencia de otros *commodities* erráticos, el cobre mantiene tendencias direccionales estructurales a mediano plazo que los componentes autorregresivos (AR) del modelo logran identificar y parametrizar eficazmente. Finalmente, la ingesta directa de esta serie desde el

Matias Davila Winder
Bachelor en Ingenieria Data Science

Banco Central asegura un linaje de datos íntegro e institucional, permitiendo el entrenamiento continuo del modelo de *Machine Learning* sin incurrir en conflictos legales de redistribución comercial.



Matias Davila Winder
Bachelor en Ingenieria Data Science

- **Activos Criptográficos Alternativos Descentralizados (Altamente Volátiles > 8%):**


- **Bitcoin / Ethereum:** A diferencia de los indicadores macroeconómicos o *commodities* tradicionales, los criptoactivos experimentan cambios de régimen frecuentes y disruptivos. Su valoración no responde a fundamentos económicos clásicos, sino que está drásticamente influenciada por inyecciones de capital institucional exógeno y por eventos algorítmicos pre-programados en su propio protocolo (como el *Halving* de Bitcoin, que reduce a la mitad la emisión monetaria de la red cada cuatro años).

Al someter estas series de tiempo a un modelo predictivo lineal y univariado como ARIMA, se producen distorsiones analíticas significativas. La alta volatilidad endógena del ecosistema criptográfico rompe constantemente los supuestos de inercia y autocorrelación a corto plazo, lo que se traduce en un sesgo elevado, registrando un Error Porcentual Absoluto Medio (MAPE) que oscila entre el 8% y el 9% durante las validaciones.

Para gestionar este riesgo a nivel de producto, el código del Dashboard (UI) implementa una estrategia de diseño defensivo. El sistema inyecta un parámetro visual que renderiza las proyecciones de estos activos en rojo bajo la etiqueta restrictiva de "Volátil". Esta advertencia categórica fuerza al usuario a comprender que, para este tipo de instrumentos, el motor predictivo univariado únicamente provee una visión direccional inconstante. El objetivo de esta barrera visual es evitar que el cliente comprometa su liquidez o tome posiciones financieras de riesgo basándose exclusivamente en una proyección probabilística que, por su propia naturaleza matemática, presenta una alta inestabilidad.

Matias Davila Winder
Bachelor en Ingenieria Data Science

Integración de Resultados Contextuales (Agente Sclooda RAG)



En la interfaz final del Dashboard Web de la plataforma, los resultados crudos generados por los modelos predictivos de Series de Tiempo y los rankings tarifarios presentan un desafío cognitivo para el usuario civil. La exposición directa a matrices numéricas, intervalos de confianza o gráficos estadísticos puros (como el output de un modelo ARIMA), por muy precisos matemáticamente que sean, a menudo carece de utilidad práctica si el usuario final no posee la educación financiera necesaria para interpretar la causalidad de dichos datos. Este fenómeno hace indispensable transitar desde un modelo predictivo tradicional hacia un paradigma de Inteligencia Artificial Explicable.

Para ilustrar esta brecha de explicabilidad, considérese el impacto de las materias primas en la economía local. Si el panel interactivo indica gráficamente que el modelo ARIMA proyecta una fuerte tendencia estocástica al alza en la cotización del Cobre (rompiendo la barrera de los US\$ 4.54 la libra), un usuario estándar podría aislar este dato y no asimilar las implicancias prácticas en su economía personal. Es imperativo que el sistema sea capaz de explicar la asincronía cruzada de los mercados, un alza sostenida del principal producto de exportación nacional presiona estructuralmente a la baja el tipo de cambio (USD/CLP) debido a la mayor inyección de divisas. A nivel de usuario de banca minorista, esto se traduce directamente en un abaratamiento de sus compras internacionales pagadas con tarjetas de crédito, una reducción en los costos de servicios digitales importados y una ventana de oportunidad para liquidar deudas indexadas a la divisa norteamericana.

Matias Davila Winder
Bachelor en Ingenieria Data Science

Para resolver sistémicamente esta brecha, la arquitectura de CostBench integra a "Scloda", un módulo cognitivo mediador diseñado para actuar como un puente semántico. Este agente no opera como un simple chatbot genérico, sino que está orquestado como un microservicio independiente dentro de la topología de contenedores del ecosistema. Su función principal es interceptar de manera dinámica las predicciones estadísticas generadas en milisegundos por el backend transaccional en Python (Flask), justo antes de que estas sean expuestas en el Frontend (React).

A nivel de flujo de datos, Scloda opera bajo un esquema de Generación Aumentada por Recuperación (RAG). El sistema captura la lectura univariada predictiva (incluyendo métricas de error como el MAPE y los coeficientes de varianza) y la fusiona con el contexto macroeconómico actual mediante ingeniería de prompts. Al inyectar estos parámetros duros en un Modelo de Lenguaje Extenso (LLM), el agente transforma un *output* puramente matemático y frío en una inferencia pragmática. El resultado es un consejo financiero accionable, redactado en lenguaje natural, que asiste al inversor o navegante civil en la toma de decisiones, respetando siempre los límites fiduciarios y legales del sistema.

Ingeniería de Prompts (`AI_PROMPT_GUIDE.md` Estándar Transaccional RAG)

Para restringir, auditar inescrutablemente e incidir dogmáticamente riguroso estructural imperativo en el vector subyacente matriz direccional analítica y la parametrización escalar pragmática comunicacional interconectada de red, las directrices subyugantes maestras inyectables iniciales al núcleo tensor de inferencia sintética semántica estructural LLM Fundacional (Gran Contexto Geminizado en Flash Estándar Modelo 2.0 Base OpenRouter API) se enclaustraron obligatoriamente aisladas pre-estructuradas en código texto duro inviolable de directrices formales estacionales parametrizables operacionales directas.

Este archivo cardinal en el código fuente pre-ensambla la matriz lógica rectora ex-ante transaccional inyectada por API previo al RAG orgánico, y obliga inexcusablemente restrictivamente a la unidad estocástica IA al cumplimiento estricto formativo legal de:

- **Redacción de Analista Financiero:** Deniega categóricamente desvíos triviales sintácticos conversacionales superficiales o de IA general o de asistente charlatán digital; asimila dogmático y asume obligatoriamente el encuadre estructural estricto de roles ("*Personas*") focalizado orgánico puramente pragmático financiero institucional.
- **Traducción Literal Estocástica Numérica:** Frente a una ráfaga y vector de entrada inyectada numérica referitiva interna exógena métrica subyacente arrojando *Outputs Data Arrays MAPE Error % 2.5 y Series Temporales AIC y coeficientes paramétricos AR/MA vectoriales*, su *System Prompt* matriz interna estructurada directriz le confiere imperativo y dicta taxativamente vectorizado obligar exiguamente a derivar procesado estructuradamente exógeno explicaciones análogas llanas contextuales humanas transaccionales (Ejemplo explicativo asimilable paramétrico generado: "*El pronóstico subyacente procesado cuenta y exhibe en su base interna métrica paramétrica de varianza dimensional validatoria inter-funcional rigurosa estadística un nivel y escalope*")

Matias Davila Winder
Bachelor en Ingenieria Data Science

y estrado de dispersión de error puramente mínimo empírico dimensional, equivalente aproximativamente paramétrico a dictaminar una vacilación oscilatoria estadística puramente estimada marginal desvíos puros absolutos y residuales equivalen estocástica en desviación a penas veinte y cinco dólares inter-estimados desfases residuales cada mil dólares promedios expuestos dimensionados predictores en test de proyecciones a plazos ciegos...).

- **Marco Legal Pre-ensamblado Protector Inyectado Forzoso Fiduciario Obligatorio Fijo (Disclaimers Legal Protectors):** Sella, inserta y amarra inherentemente en cada ráfaga conclusiva recomendativa finalizada proyectada y expuesta orgánicamente, una franja restrictamente asertiva y disuasoria exentando la app asilante paramétrica prevenida asimilando dictamen explicativo legal estricto que dictamina: "Esta proyección matemática asintótica predictiva no sustituye un mandato corporativo institucional asesor activo ni exime de deberes fiduciales institucionales reguladores del país local analista del país; proyecciones empíricas algorítmicas no son recomendaciones certeras irrefutables directas y finales garantizadoras institucionales vinculantes de inversión."

Roster de Personalidad Multidisciplinaria

A través del archivo orientador transaccional matriz orientativo, Scloda adopta y transiciona dinámicamente perfiles vectoriales actitudinales modulares instanciados parametrizados dependiendo cardinal de la métrica dimensional ex-ante proyectiva analizada e ingresada cruda interconectada vía API al agente IA LLM pre-ensamblado:

- **Científico de Datos e Ingeniero Machine Learning Activo Asilante:** Al ser consultada su instancia cruzada dimensional metodológica algorítmica estocástica predictivo, el Agente previene, transmuta dimensional y asimila la forma formativa asilante experta didáctica estadística docente de orientador, impartiendo clarividente interconectada lógica de un ARIMA diferencial estacionario pre configurado paramétricamente sin caer en superficialidades ingenuas orgánicas genéricas de lenguajes llano no especializados irrelevantes.
- **Experto Macro-Analítico Cuantitativo Financiero Economista Bursátil Bancario:** Tras inter-alimentarse vectorial exógena métricamente pre-parametrista ingresante desde la de las matrices dimensionales Base Datos ranking Benchmark ATC Cuentas vistas chilenas tabulares transaccionales, se transfigura mutante direccional operativo al rol crítico confrontación revelador institucional incisivo inquisitivo empoderador civil asilado del *Pragmatic Banker*, desnudando la asimetría de precios tarifarios irracionales de la banca y recomendando, visibilizando matemáticas alternativas transparentes institucionales de bajas cuotas.

Hiper-personalización Financiera (Modo Sniper y RAG Dinámico)

El valor diferencial de CostBench radica en que la Inteligencia Artificial no dialoga de la misma manera con todos los usuarios. Gracias al módulo de autenticación (JWT), la base de datos PostgreSQL almacena el Perfil de Riesgo de cada usuario (Conservador, Moderado o Agresivo).

Matias Davila Winder
Bachelor en Ingenieria Data Science

Mediante un patrón interno que denominamos Modo Sniper, el Backend en Flask extrae este perfil de usuario justo antes de enviar la consulta al LLM. El sistema concatena esta información al System Prompt de ScloDa de forma dinámica (On-the-fly).

Este enfoque de RAG Dinámico asegura que la Inteligencia Artificial adapte sus consejos frente a un mismo escenario macroeconómico. Por ejemplo:

- Si un usuario **Conservador** pregunta sobre una caída en las tasas de interés globales, ScloDa sugerirá estrategias para proteger el capital en instrumentos de renta fija segura (como Depósitos a Plazo) antes de que las tasas sigan bajando.
- Si un usuario **Agresivo** hace la misma consulta, el Prompt dinámico hará que ScloDa se enfoque en las oportunidades de mercado, como la posibilidad de refinanciar deuda hipotecaria a menor costo o buscar rentabilidad en activos más volátiles.

Esta integración justifica técnicamente la necesidad de haber construido un sistema de Login y gestión de usuarios sobre una plataforma de análisis macroeconómico.

Arquitectura e Ingeniería de Software del Ecosistema

La encriptación, almacenamiento y orquestación del análisis macro-bancario se materializa computacionalmente a través de un ecosistema formal resiliente estructurado programáticamente orientado funcional de capas intermediarias *Backend* integrativa operante interactivo con un *Frontend* asíncrono dinámico desplegadas paramétricamente aisladas empaquetadas modular transaccional *Dockerizadas*.

Topología del Stack Tecnológico

1. **Núcleo Análítico de Exposición Web (Backend Python en MicroFramework RESTful Asíncrono de Interoperatividad Rápida):** Se erige la espina dorsal integrando la algorítmica y orquestativa de Base Datos operante central implementando el marco liviano `Flask`. Este framework provee resiliencia asilante liviana de conectividad desprovista carente de pesados aparatajes irrelevantes inoperantes (Como monolíticamente pesados empaquetamientos estructurales obsoletos pre-establecidos de Django), favoreciendo asimétricamente un enfoque microservicios iterativo atípico asilante donde librerías pesadas C++ transaccionales de procesamiento estocástico matriciales pesadas transaccionales como Scikit-Learn y pmdarima pre compilados pueden respirar libres de hilos innecesariamente desproporcionados asíncronos paralelos estancadores asiladores pesados Web redundantes transaccionales, interconectándose limpiamente en un API REST de comunicación transaccional rápida HTTP interconectada asilada json.
2. **Panel Web Visual Reactivo Dinámico (Frontend Interactivo Inter Operativo Unificado Single Page App React.js):** La renderización de métricas y tarjetas estocásticas se desacopla utilizando librerías orgánicas y lógicas **React.js**, previniendo de facto perjudiciales cargas estancadores pesadas recargas enteras forzadas transversales

Matias Davila Winder
Bachelor en Ingenieria Data Science

inestables preestablecidos desfazadas interconectadas totales web completas desfazadas antiguas. Módulos reactivos independientes (Ej: Gráfico Cobre interactivo) pueden requerir sub datos mutables tras requerimientos pre conectados asíncronos operantes tras fondos puramente al server sin afectar u asilar ni corromper ni colapsar renderizadas actividades inamovibles congeladas adyacentes estables inalterados asiladores fijos adyacentes estabilizados pasivos.

Catálogo y Linaje de Datos


Se mantiene trazabilidad de la "Verdad Terrestre" desde su nacimiento HTML web hasta su solidificación final.

- *Ingestas y Derivaciones Operacionales CMF Cuentas Tabulares HTML dinámicas:* Procesamiento asilante purificador agresivo destructivo duro Regex que normaliza numéricamente valores dispares y pre computa algebraico rígido univariado aritmético simple asilando al Costo Operacional Final (ATC Anual). Se guardan vectoriales primarios limpios asilados en *Data Lakes Parquet*.

Modelo Relacional de Datos (ER) y Resiliencia Estructural Continúa Defensiva Operativa Upserts (PostgreSQL)

Bajo directrices operacionales productivas de ORM (SQLAlchemy Postgres), erradicamos la inyección transaccional estática pasiva ingenua o simplista destructiva. Implementamos inyecciones incrementales lógicas de "Upsert". Al interceptar series macro duplicadas (La UF histórica inalterada anterior que pre existe inamovible guardada insertada ayer intocable histórica en PostgreSQL relacional), la inserción conflictiva no aborta operando *crash server kill logs panics 500 error* ni borra masiva, sino que ignora, avanza, fluye y silenciosamente actualiza y previene estigmas de caídas asilando índices puros y tablas operativas integras 100% resilientes continuas estables seguras productivas en-vivo blindadas ininterrumpidamente transaccionales.

Matias Davila Winder
Bachelor en Ingenieria Data Science



El diseño separa las lógicas estáticas (Institution y Product) de los atributos condicionales puramente dinámicos (FeeEvent y ExemptionRule). Además se aísla, sin referenciar cruzadamente y reduciendo contención, la entidad Indicator orientada al archivo histórico macroeconómico consumido por pmdarima.

Capa de Autenticación y Seguridad (JWT)

La seguridad del ecosistema se garantiza mediante Tokens Web JSON (JWT) de encriptación asimétrica. Para evitar vulnerabilidades críticas asociadas al almacenamiento en la memoria del navegador (como localStorage o sessionStorage), los tokens se encapsulan exclusivamente en Cookies HttpOnly. Esta directriz de arquitectura bloquea por diseño cualquier intento de lectura mediante código JavaScript del lado del cliente, mitigando de forma efectiva los vectores de ataque de Cross-Site Scripting (XSS).

Matias Davila Winder
Bachelor en Ingenieria Data Science

Resiliencia Concurrente y Optimización (GZIP y Deduplicación N+1)

Para asegurar que CostBench soporte escalar a múltiples usuarios concurrentes interactuando simultáneamente con paneles intensivos en datos, sin sufrir degradación de la experiencia ni colapsar la infraestructura Base, se instrumentaron rigurosas ingenierías de control de asincronía y optimizaciones de transferencia transaccional.

1. **Manejo de Concurrencia en Archivos (Exponential Backoff):** La arquitectura del proyecto presentaba un riesgo de colisión de lectura y escritura (Race Condition). El Scheduler del backend actualiza y sobrescribe los archivos `.parquet` periódicamente. Si un usuario entraba al dashboard exactamente en el mismo milisegundo en que el archivo se estaba reescribiendo, el sistema operativo bloqueaba el acceso (File Lock), lo que generaba un Error 500 en la plataforma.

Para solucionar esto y garantizar la alta disponibilidad sin sumar herramientas externas costosas como Redis, se implementó un patrón de Backoff Exponencial. Si el backend detecta que el archivo Parquet está bloqueado (error de Entrada/Salida), el sistema pausa el proceso y reintenta la lectura 3 veces con intervalos de espera crecientes (por ejemplo: 50ms, 150ms, 450ms). Esta fracción de segundo es suficiente para que el Scheduler libere el archivo, permitiendo entregar los datos al usuario de forma transparente y sin que la aplicación se caiga.

2. **Refactorización del Frontend y Supresión del Problema N+1 (React):**
 - **Deduplicación de Peticiones Asíncronas e Inflight Maps:** Durante iteraciones iniciales, los tableros interactivos (como el carrusel de tarjetas o los *Tickers* paralelos) montados simultáneamente en la interfaz producían el clásico **Problema N+1**. Al compartirse *Assets* como "Oro" o "Petróleo" en distintos flancos del panel, múltiples componentes disparaban ciegamente peticiones cruzadas a la API del núcleo Analítico de forma paralela. Estos múltiples *HTTP fetch* simultáneos infundían latencia abismal y, peor aún, multiplicaban exponencial y redundantemente las facturaciones monetarias contra los tokens y modelos fundacionales (OpenRouter). Se refactorizó el conducto migrando estas orquestaciones directas hacia *Hooks Personalizados* de modelo jerárquico unificado que inician la vida del tablero inyectando un estado global de *Mapas Promesa Inflight*. De producirse 15 consultas milimétricamente simultáneas requiriendo deducción macro por ORO, la primera se ejecuta atando conceptualmente a las demás catorce reactivamente a su lomo, retornando de forma instantánea 1 solo llamado HTTP hacia la base de datos real.
 - **Code Splitting Masivo (React.lazy):** Las librerías estadísticas pesadas requeridas por la experiencia del panel iterativo (*Chart.js*, *Framer-Motion*) castigaban el Primer Despliegue de Pintura (*First Contentful Paint*) del árbol genérico de la Web. Mediante el empaquetado granular asincrónico `lazy()`, la topología arquitectónica de react aísla los módulos subyacentes transfiriendo dichos

Matias Davila Winder
Bachelor en Ingenieria Data Science

- polígonos kilobáyticos al cliente explícitamente solo si el ratón del usuario enfoca o entra a las ventanas modales de interactividad financiera requeridas.
- **Transmisión de Archivos Hiper-Comprimidos (GZIP):** A pesar de modular la transferencia y deduplicar el JSON de salida API de Python, algunos sets históricos macro presentaban coliformes seriales de varios megabytes. Mediante interceptores en la capa intermedia o *Middleware* (Librería nativa `Flask-Compress`), todo flujo salarial se entrelaza subyacentemente al algoritmo cripto-compresivo **GZIP** antes de ser inyectado en la manguera HTTP TCP/IP. Este interceptor aplasta dinámicamente el polígono en red (*On-The-Fly*), deflactando la transferencia hasta en un 80% del peso real crudo para terminales lejanos e inestables que acceden a la plataforma desde conexiones lentas 3G chilenas ruralizadas.

Evaluación, Riesgos y Competencias Desarrolladas

- El despliegue ha sido evaluado en términos de resiliencia y reproducibilidad:
 - **Reproducibilidad Garantizada:** Todo el entorno está sellado sobre Docker. Además, en los algoritmos predictivos se fijan "semillas" estocásticas (`random_state`) en las rutinas Scikit-learn/pmdarima, posibilitando que observadores externos repliquen el *forecast* exactamente igual.
 - **Riesgo Operacional (Modificación de las fuentes):** Una perturbación o rediseño de la web de la CMF corrompería el índice de Benchmark. **Mitigación:** Se han preparado plantillas *fall-back* estructuradas de actualización y carga manual asíncrona.
 - **Riesgo Sistémico y Ético (Alucinación IA):** Falsos augurios bursátiles que induzcan compra irresponsable por parte de individuos. **Mitigación:** Estricto cumplimiento en la UI de *Disclaimers* que categorizan a Scloda taxativamente como herramienta educativa/estratégica, y no como servicio institucional de Asesoría Financiera Fiduciaria. Asimismo, activos sin fundamentos de valoración tradicional (ej. Criptomonedas) ingresan "apagados" para el pronóstico por el sistema por alta varianza irrestricta.

Competencias Desarrolladas (Niveles propuestos 1 a 5)

- **Estructurar información (Nivel 5):** Esquema canónico, parseo forzoso de datos web a numéricos y validaciones sanitizadas a partir de datos reales heterogéneos.
- **Diseñar sistemas de datos (Nivel 4):** Consolidación fluida entre formato parquet nativo inicial hacia abstracción relacional mediante PostgreSQL ORM en fases posteriores.
- **Técnicas de ML (Nivel 4):** Orquestación autogestionada con `pmdarima` evaluando campeonatos paramétricos internos. Integración programática determinista para *benchmarking*.
- **Modelización Estadística (Nivel 4):** Inferencia estocástica, previsoras univariadas, índices base UF, escalamiento y ranking de cuartiles de precios.

Matias Davila Winder
Bachelor en Ingenieria Data Science

- **Cumplimiento legal y normativo (Nivel 4):** Diseño de ingestas puramente documentadas gubernamentales (Licence-Safe). Sin riesgos PII (Personal Identifiable Information).
- **Visualización (Nivel 3):** Desarrollo de SPA responsiva interactuando componentes React sobre el motor analítico.

Desarrollo Viable y Sostenible (ODS) y Green Computing

El desarrollo de CostBench no responde únicamente a una necesidad técnica o de mercado, sino que se alinea profundamente con los Objetivos de Desarrollo Sostenible (ODS) propuestos por la Organización de las Naciones Unidas (ONU), integrando consideraciones sociales, económicas y medioambientales en su arquitectura algorítmica y de software.

Mitigación de Asimetrías de Información y Empoderamiento.

El ODS 10 busca explícitamente "Reducir la desigualdad en y entre los países". En el sistema financiero chileno moderno, la desigualdad no solo se manifiesta en la distribución estática de la riqueza, sino también en el acceso a la educación e información financiera. La fragmentación intencional de las estructuras tarifarias bancarias (costos de mantención condicionales, comisiones por giros físicos, tarifas cruzadas por saldo promedio) crea una barrera cognitiva. Los usuarios con menor educación financiera o de segmentos socioeconómicos vulnerables terminan, paradójicamente, pagando mayores costos operativos (Costo Total Anual - ATC) por mantener su liquidez, en contraposición a los usuarios de altos ingresos bancarizados en instituciones premium que gozan de exenciones totales de cobros.

CostBench democratiza el conocimiento financiero al actuar como un fideicomisario analítico neutral que consolida, estandariza y rankea estas tarifas difusas. Al otorgar visibilidad absoluta sobre la verdadera "Frontera de Eficiencia" del mercado (visibilizando sistemáticamente a cooperativas de ahorro y crédito o bancos digitales costo-cero frente al retail tradicional), la plataforma transfiere el poder simétrico de decisión de vuelta al consumidor.

La capa cognitiva, impulsada por el agente conversacional de Inteligencia Artificial (Scloda), amplifica sustancialmente este impacto social inclusivo: traduce proyecciones macroeconómicas estocásticas herméticas—como la pendiente de la curva de rendimiento de los bonos del tesoro (Yields) o la volatilidad geométrica histórica de la Unidad de Fomento (UF)—a un dialecto conversacional accesible y didáctico. Este diseño centrado en el usuario (UX) empodera a individuos desprovistos de formación económica formal para que optimicen su posición de depósitos y protejan eficientemente su poder adquisitivo contra presiones inflacionarias agresivas.

11.2. Eficiencia de Software y Green Computing (ODS 12 y ODS 13) El desarrollo sostenible exige que las soluciones tecnológicas evalúen su costo computacional y energético. El uso intensivo de Machine Learning suele generar un alto consumo energético en los servidores en la nube, impactando directamente en la huella de carbono.

Matias Davila Winder
Bachelor en Ingenieria Data Science

En las fases iniciales del proyecto, se contempló usar PyCaret para orquestar los modelos predictivos. Aunque PyCaret es excelente para experimentar rápidamente porque entrena decenas de modelos en paralelo, resultó ser demasiado pesado para el entorno de producción. Mantenerlo activo requería contenedores Docker con gran cantidad de memoria RAM y uso intensivo de CPU, lo que aumentaba innecesariamente los costos operativos y el impacto térmico del servidor.

La decisión de refactorizar el código para usar directamente `pmdarima` (y heurísticas simples como Random Walk) responde a un enfoque de eficiencia estricto (Green Computing). Con este cambio arquitectónico, se logró:

1. **Reducción de Infraestructura:** La imagen Docker de la API de Machine Learning se redujo en más de un 70%, bajando drásticamente los requerimientos de hardware instalados.
2. **Menor consumo de CPU:** En lugar de usar fuerza bruta para probar modelos masivos de forma paralela, `pmdarima` realiza una búsqueda dirigida y secuencial, siendo mucho más eficiente a nivel energético.
3. **Ejecución bajo demanda:** El reentrenamiento de los modelos se programó para ejecutarse de forma asíncrona cada 15 días. Los modelos ganadores se serializan y guardan en archivos `.pkl`, por lo que cuando un usuario entra a la web, el sistema solo carga el modelo pre-entrenado y hace la predicción en milisegundos, sin estresar los procesadores del servidor ni consumir Kilo vatios-hora (kWh) adicionales por cada consulta.

Conclusiones y Roadmap

El desarrollo de CostBench en su fase actual ha demostrado con éxito la viabilidad técnica de integrar el análisis microeconómico de tarifas bancarias estáticas con la predicción macroeconómica dinámica. A nivel de Ingeniería de Datos, el sistema logró consolidar, limpiar y estandarizar la dispersión de cobros del mercado financiero chileno. Mediante la derivación matemática del Costo Total Anual (ATC), la plataforma logró desmitificar la opacidad estructural de los productos transaccionales, estableciendo una frontera de eficiencia objetiva y auditable para el consumidor.

Desde la perspectiva de la Ciencia de Datos, la implementación del pipeline analítico basado en modelos estocásticos univariados (`pmdarima`) probó ser una solución robusta y eficiente para entornos de producción. Las evaluaciones empíricas y el Hold-out testing confirmaron que los modelos autorregresivos (ARIMA) logran capturar con altísima precisión la inercia de índices estructurados como la Unidad de Fomento ($\text{MAPE} < 1\%$) y activos refugio como el Oro. Esto justificó matemáticamente la decisión arquitectónica de priorizar la explicabilidad estadística lineal por encima de modelos opacos de caja negra.


Finalmente, el mayor logro integrativo del ecosistema radica en la resolución de la barrera cognitiva del usuario final. Mediante la instrumentación de un flujo de Generación Aumentada

Matias Davila Winder
Bachelor en Ingenieria Data Science


por Recuperación (RAG Dinámico) y la inyección del Perfil de Riesgo mediante tokens seguros (JWT), el agente cognitivo "Scloda" consigue traducir outputs estadísticos puros en recomendaciones financieras asimilables. Con esto, la plataforma trasciende la mera visualización de tableros de datos, consolidándose como una herramienta de Inteligencia Artificial Explicable (XAI) que empodera activamente al ciudadano frente a la asimetría de información del sistema bancario tradicional.

Visualización del Cronograma y Sprints Restantes Metodológicos:

Para garantizar la viabilidad técnica y el cumplimiento sistémico de los objetivos, el proyecto se rige por un cronograma jerárquico de tres macrotapas, ilustradas a continuación



(CostBench omite explícitamente del alcance modelos de High Frequency Trading - HFT o Redes Neuronales Profundas tipo LSTM, cuyo déficit de explicabilidad inherente iría contra la naturaleza transparente requerida en el Benchmark).



Matias Davila Winder
Bachelor en Ingenieria Data Science

Referencias

(Banco Central de Chile, 2025)

(Comisión para el Mercado Financiero, 2025)

(Comisión para el Mercado Financiero, 2025)

(Hyndman & Athanasopoulos, 2018)

(Smith & Developers, 2025)

(OpenRouter & Google DeepMind, 2025)

(Federal Reserve Economic Data, 2025)

(Akerlof, 1970)

(Dickey & Fuller, 1979)

(Box & Jenkins, 1970)